INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ

IFCE *CAMPUS* TAUÁ

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

MARÍLIA DA SILVA FEITOSA

RELATÓRIO DE EXPERIMENTAÇÃO: REDES NEURAIS ARTIFICIAIS CLÁSSICAS

Perceptron, ADALINE e MLP aplicados ao conjunto Iris

DISCIPLINA: INTELIGÊNCIA COMPUTACIONAL

PROFESSOR: REGINALDO FERNANDES

TAUÁ

2026

1. Introdução e Contextualização do Problema

O conjunto de dados *Iris*, introduzido por Ronald Fisher, é um marco no estudo de reconhecimento de padrões. Ele consiste em 150 amostras de três espécies de flores (Setosa, Versicolor e Virginica), com quatro atributos físicos. O problema central reside na classificação dessas espécies, sendo que uma delas (Setosa) é linearmente separável, enquanto as outras duas apresentam sobreposição em suas distribuições. Este trabalho busca aplicar e comparar três modelos de Redes Neurais Artificiais para resolver este problema de classificação supervisionada.

2. Fundamentação Teórica

2.1 Perceptron (Camada Única)

O Perceptron é um classificador linear cuja saída é determinada por uma função de ativação degrau unitário. Sua regra de aprendizado ajusta os pesos proporcionalmente ao erro de classificação.

- **Implicações Geométricas:** Ele cria um hiperplano (uma linha no espaço 2D) que divide o espaço de atributos.
- **Limitação:** Se os dados não forem perfeitamente separáveis por uma linha, o algoritmo não converge para erro zero, apresentando oscilações.

2.2 ADALINE (Adaptive Linear Neuron)

O ADALINE diferencia-se do Perceptron por utilizar uma função de ativação linear durante a fase de treinamento. O ajuste de pesos é realizado através da minimização do Erro Quadrático Médio (MSE) utilizando o gradiente descendente.

- **Vantagem:** Oferece uma convergência mais estável e lida melhor com ruídos, pois foca na redução do erro contínuo antes da classificação final.

2.3 MLP (Multilayer Perceptron)

O MLP é uma rede neural profunda com pelo menos uma camada oculta. Utiliza funções de ativação não-lineares (como ReLU ou Sigmoide) e o algoritmo *Backpropagation* para ajuste de pesos.

- **Capacidade:** Diferente dos modelos anteriores, o MLP possui capacidade de aproximação universal, conseguindo gerar fronteiras de decisão complexas e curvas para separar dados não-lineares.

3. Metodologia Experimental

3.1 Dados e Pré-processamento

Utilizou-se o dataset Iris integral (150 amostras). O pré-processamento consistiu na **Padronização (StandardScaler)**, transformando os atributos para média 0 e desvio padrão 1. Para a visualização de fronteiras, os modelos foram treinados utilizando apenas dois atributos (comprimento e largura da pétala).

3.2 Treinamento e Teste

O experimento seguiu um rigoroso protocolo de 10 execuções independentes. Em cada rodada:

- Os dados foram embaralhados e divididos em 70% para treino e 30% para teste.
- Utilizou-se o *random_state* de 0 a 9 para garantir variabilidade e reprodutibilidade.

4. Resultados Experimentais

Os resultados obtidos através das execuções no ambiente VS Code foram:

Modelo	**Acurácia Média**	**Desvio Padrão**
Perceptron	86,89%	0,0956
ADALINE	82,89%	0,0597
MLP	94,44%	0,0425

4.1 Matrizes de Confusão

As matrizes de confusão permitem visualizar o desempenho dos modelos em cada classe específica, revelando onde ocorreram os erros de classificação.

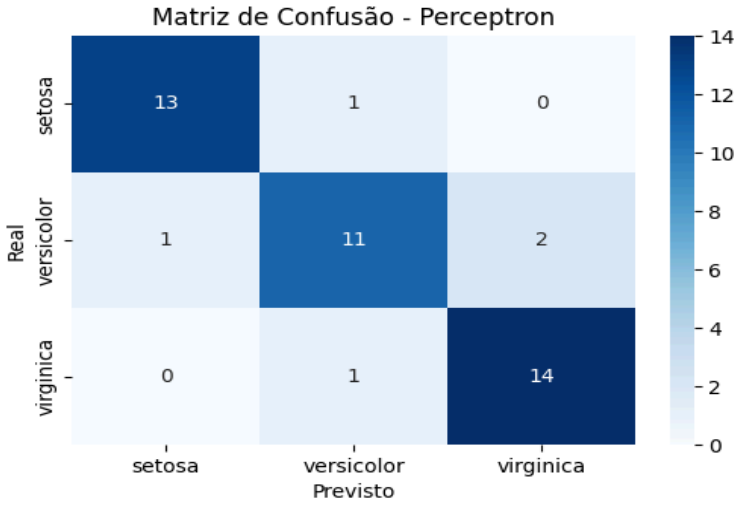

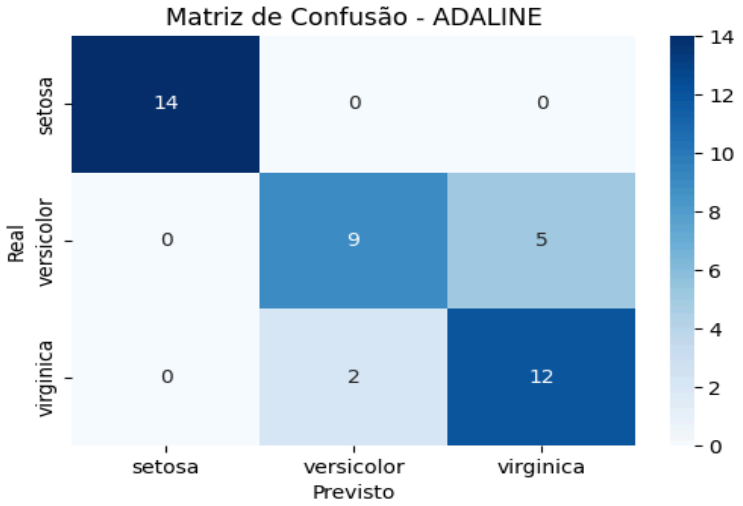

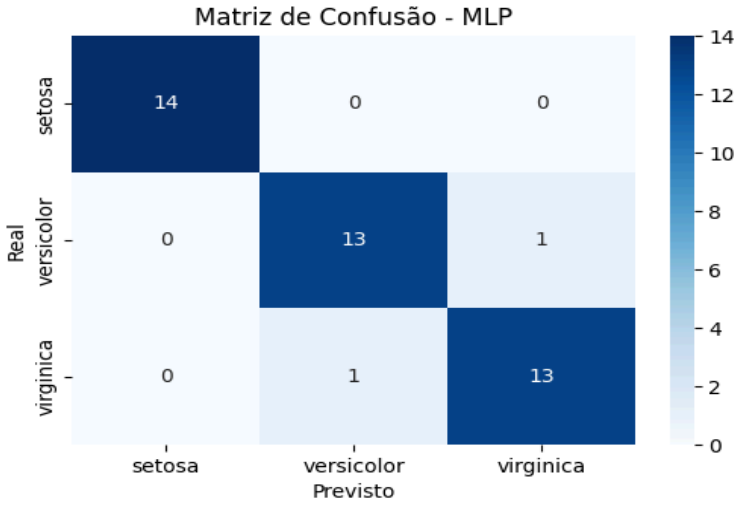

Matriz do Perceptron: Mostra a separação perfeita da classe *Setosa*, mas com confusões entre *Versicolor* e *Virginica*.

Matriz do ADALINE: Semelhante ao Perceptron, evidenciando a dificuldade linear em separar as classes sobrepostas.

Matriz do MLP: Deve apresentar os maiores valores na diagonal principal, demonstrando que a rede não-linear conseguiu distinguir melhor as flores que possuem medidas muito próximas.

5. Visualização e Análise das Fronteiras de Decisão

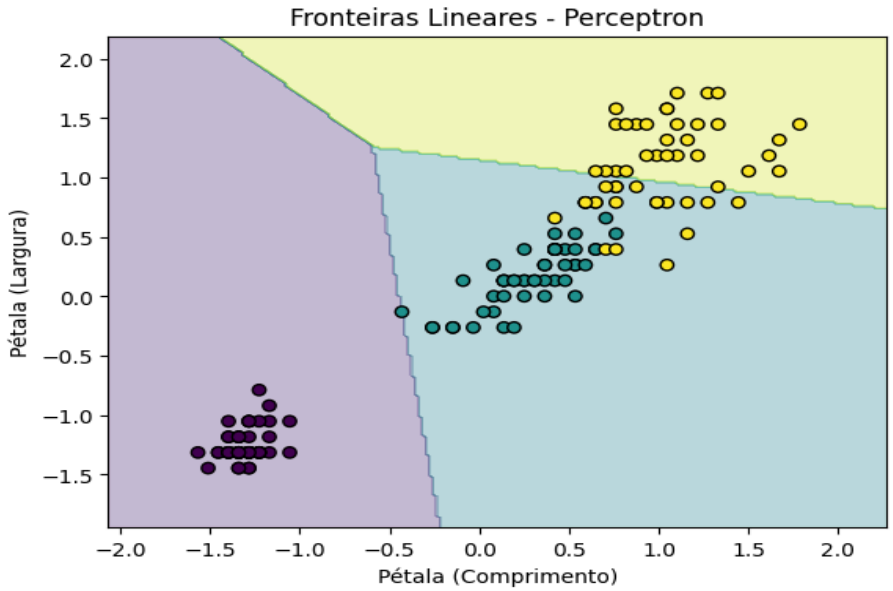

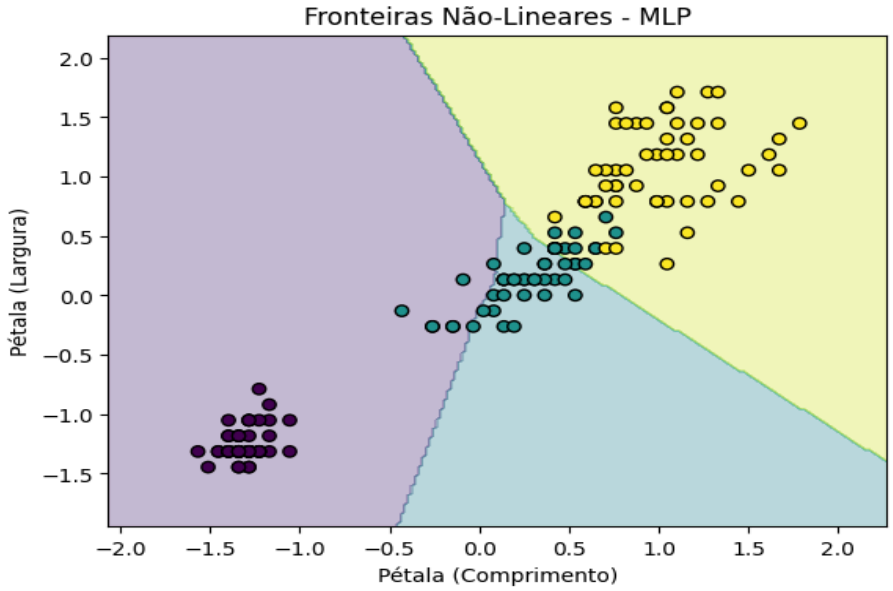

Análise Visual:

- **Fronteiras Lineares (Perceptron/ADALINE):** Observa-se que a linha reta falha em capturar a distribuição de pontos na zona de intersecção entre as classes 1 e 2.
- **Fronteiras Não-Lineares (MLP):** O gráfico exibe regiões de decisão curvas. Essa geometria permite que a rede "contorne" amostras difíceis, resultando em um desempenho quantitativo superior.

6. Discussão Crítica Comparativa

Ao comparar os três modelos, o **MLP** apresentou o melhor desempenho (94,44% de acurácia), validando a necessidade de camadas ocultas para lidar com a complexidade do conjunto Iris. O **Perceptron** obteve resultados satisfatórios, mas sua alta variabilidade (desvio padrão de 0,09) indica sensibilidade à forma como os dados são divididos. O **ADALINE**, embora com acurácia média ligeiramente inferior neste experimento, mostrou-se mais estável que o Perceptron. Conclui-se que para problemas reais onde a separabilidade linear não é garantida, modelos não-lineares como o MLP são indispensáveis, apesar do maior custo computacional de treinamento.